

论文笔记: DealMVC: Dual Contrastive Calibration for Multi-view Clustering

简介信息

作者: Xihong Yang, Jin Jiaqi, Siwei Wang, Ke Liang, Yue Liu, Yi Wen, Suyuan Liu, Sihang Zhou, Xinwang Liu, En Zhu

文献类型: 会议

影响因子: 13.36900

文献来源: MM 2023

原文链接: <https://dl.acm.org/doi/pdf/10.1145/3581783.3611951>

关键词: Deep multi-view clustering、Deep Learning、Multi-view、Contrastive Learning、Clustering

论文结构

- Abstract
- 1. Introduction
- 2. Related Work
 - 2.1 Multi-View Clustering
 - 2.2 Contrastive Clustering
- 3. Methodology
 - 3.1 AutoEncoder Module
 - 3.2 Adaptive Global Fusion Module
 - 3.3 Dual Contrastive Calibration Module
 - 3.4 Objective Function
- 4. Experiments
 - 4.1 Dataset
 - 4.2 Experiment Setup
 - 4.3 Performance Comparison (RQ1)


- 4.4 Ablation Studies (RQ2)
- 4.5 Hyper-parameter Analysis (RQ3)
- 4.6 Visualization Analysis (RQ4)
- 5. Conclusion

研究问题

- 大多数现有方法只关注不同视图下相同样本的一致性，忽略了跨视图场景下不同样本的相似性。

研究方法

作者提出了一种用于多视图聚类的新型双对比校准网络，称为 DealMVC。具体来说，DealMVC首先设计了一种自适应全局融合机制，以两种方式获取全局跨视图特征，即**注意力机制和可学习的视图采样网络**。之后，作者设计了一个**全局对比校准损失**来保证样本具有相似的特征，它将**视图特征相似度图和高置信度伪标签图对齐**。为了进一步挖掘多视图信息的多样性，作者为成对视图设计了**局部对比校准损失**。跨视图特征的结构与可靠的类信息一致。在训练过程中，视图特征和高置信度伪标签被联合优化，并与双对比校准损失相互作用。



研究结论

- 该算法提出了一种新颖的深度对比多视图聚类算法，称为DealMVC。双对比校准机制保持了跨视图场景下相似但不同样本的一致性。

- 通过**对齐视图特征相似度图和高置信度伪标签图**，视图特征结构受到可靠的类信息的约束。
- 利用相同的方式两两对比特征的一致性，进而提出了局部对比损失，保证相似样本在不同视图下具有相似的特征。

创新不足

- 创新
 - 全局特征通过对齐伪标签图和特征相似图，不断迭代网络更新参数，没有跟单个视图交互。
 - 通过**可学习的视图采样网络和注意力机制融合**出全局特征。
- 不足
 - DealMVC的全局对准损失的**第一部分除以一个会变的负样本**，所以这部分可以改进！
 - **分母是所有样本对的相似度，这与导致同一类的样本也被推远，这与聚类目标是相违背的。因此需要改进分母的部分**
 - DealMVC并没有按照论文说的那样去对齐标签图和特征相似图。
 - 最后的一致性损失并没有实际作用。
 - 融合机制还没有直接拼接经过一层全连接网络得到的效果好。

$$\mathcal{L}_{global} = -\mathbf{W}_{ii}^G \log \left(\frac{\exp(\mathbf{S}_{ii}^G)}{\sum \exp(\mathbf{S}_{ij}^G)} \right) - \sum_{j=1, j \neq i}^N \mathbf{W}_{ij}^G \log \left(\frac{\exp(\mathbf{S}_{ij}^G)}{\sum \exp(\mathbf{S}_{ij}^G)} \right).$$

感悟心得

- 针对上述说的是对准损失问题，通过改变高置信度伪标签矩阵的约束方法，我们通过比较样本之间的数据分布，得到一个增强的关联矩阵，并根据其选择正样本和负样本，通过拉近正样本，推开负样本的方式，我们提出了以下方法来改进：

$$\mathcal{L} = - \sum_{j=1}^N \log\left(\frac{W_{ij}e^{S_{ij}}}{\sum (1 - W_{ij})e^{S_{ij}}}\right)$$

- 在组内讨论的时候，我们发现以下两种现象
 - 通过knn构图，我们会得到 bn/k 张邻近图，通过约束每个样本之间的邻居，我们获取样本之间的结构性关系，其本质上是**通过很多张小图合并为一些大图**来达到聚类的效果。
 - 通过相似图裁剪，我们可以得到一些小图，通过动态的迭代分割的阈值，我们得到的结果也会越来越精确，其本质上是**通过将一张大图裁剪成一些小图**来达到聚类的效果。
 - 通过knn构图和相似图裁剪，我们可以将真实的聚类结果控制在二者之间，通过不断的夹紧二者的边界，我们最后会得到出色的性能。