

论文笔记： Bridging Gaps Federated Multi-View Clustering in Heterogeneous Hybrid Views

简介信息

作者： Yazhou Ren

文献类型： 期刊

影响因子： 10.0000

文献来源： NeurIPS2024

原文链接： <https://openreview.net/pdf?id=GVIJ VX3iiq>

源码链接： <https://github.com/5Martina5/FMCSC>

关键词： Multi-view clustering、 Federated learning、 Data fusion


论文结构

- Abstract
- 1.Introduction
- 2.Related Work
- 3.Methodology
- 4.Experiments
- 5.Conclusion

研究问题

- 现有联邦方法通常假设**客户端都是同构的**，且所有**客户端都属于单视图或多视图客户端**。

- 单视图客户端和多视图客户端表现出不同程度的异构性，且客户端之间也存在功能异构或特征异构，即**视图间隙和客户端间隙**问题。
 - **客户端间隙**：多视图客户端具有更**全面**的集群分区，而单视图客户端却更容易有**偏差**。
 - **视图偏差**：不同客户端收集的**混合视图之间具有质量差异**。
- **示例**：大城市的医院采用CT、X射线和EHR进行疾病监测，而偏远地区通常依赖于单一的检测方法。相似地，智能手机可以捕获音频和图像，但是记录设备只能收集音频数据。



研究方法

本文提出了一种联邦多视图聚类方法（FMCSC），以消除混合视图联邦方法中客户端和视图端之间的鸿沟。具体的操作步骤如下：

- **在客户端环境中**：多视图客户端和单视图客户端**共享自编码器训练参数**。
 - 在多视图客户端中，该方法采用了与GCFAggMVC类似的操作，将每个视图的高级特征与所有视图的统一特征做对比损失。
 - 在单视图客户端中，令单视图的高级特征与全局服务器端的统一特征做对比损失，但是**负样本是单视图的低级特征（即自编码器**

的潜在特征)

- 在服务器端环境下：利用互信息进行全局加权融合获取全局的参数。

研究结论

- 该工作提出了一种新的FedMVC方法，该方法从弥合客户端和视图鸿沟的角度出发，解决了异构混合视图的问题，并通过理论分析解释了其成功机制。
- 该方法设计了局部协同对比学习和全局特定加权聚合，利用互信息作为连接局部和全局模型的桥梁，探索分布在不同客户端的多视图数据的聚类结构。

创新不足

- 创新
 - 考虑了客户端和视图之间的鸿沟，并利用联邦学习的框架将他们统一在同一框架下
- 问题

感悟心得

- 思考

笔记摘抄

- FedMVFPC假设数据分布在多个客户端中，每个客户端都有V个视图，但是客户端之间的样本不重叠。但其实客户端之间的样本是会存在折叠的。

- 现有联邦多视图聚类方法可以根据多视图数据在客户端之间的划分分为两类
 - **纵向FedMVC**：假设具有 V 个视图的数据集分布在 V 个单视图客户端，每个客户端具有相同的数据集。
 - **挑战**：仍然依赖于理想主义的假设，即同一样本的不同视图可以在客户端之间对齐。
 - **横向FedMVC**：假设数据分布在**多个多视图客户端**之间，每个客户端具有 V 个视图，并且**客户端之间的样本不重叠**。
 - **挑战**：横向FedMVC的目的是通过在多个客户端之间共享训练模型来提高局部疾病预测性能。但他们在处理具有异类混合视图的实际FedMVC场景中仍然存在局限性。
- 异构性是指**客户端之间的差异**，其中单视图和多视图客户端共存。混合视图表明训练过程中涉及的**视图数量和质量的不确定性**。
- **没有共识预训练**的全局模型的输出显示出**无法清楚区分的混合特征**。
- **直接参数聚合**会导致**模型错位**，表现为特征空间的**特征混淆**。