

论文笔记：A Hubness Perspective on Representation Learning for Graph-Based Multi-View Clustering

《从表示学习中的一个中心视角来看待基于图的多视图聚类》

简介信息

作者：Zheming Xu, He Liu, Congyan Lang, Tao Wang, Yidong Li, Michael C. Kampffmeyer

文献类型：会议

影响因子：[8.9](#)

文献来源：CVPR 2025

原文链接：[A Hubness Perspective on Representation Learning for Graph-Based Multi-View Clustering](#)

源码链接：<https://github.com/zmxu196/hubREP>

关键词：[#Hubness](#) [#Graph-Multi-view-Clustering](#)

论文结构

- Abstract
- 1.Introduction
- 2.Related Work
- 3.Motivation
- 4.Method
- 5.Experiment
- 6.Conclusion

研究问题

基于图的多视图聚类（GMVC）方法通常将视图特征编码到高维空间中，并根据距离相似度构建图。然而，高维嵌入通常会导致Hubness问题，即少数点会重复出现在其他点的最近邻列


表中。这会对提取的图结构和消息传递产生负面影响。

- 某些数据点（称为hubs）经常出现在许多其他点的最近邻中。
- 中心显著影响基于图的任务，例如基于距离的图构建和消息传播。


实验观察

实验观察 1

在MVC中，hubness问题很普遍。由下图可见，随着 d 的增加，直方图变得更加右倾，表明更多样本经常出现在其他样本的邻域中。




其次，本文可视化了不同视图偏度的绝对差异，如下图所示，同一样本在不同视图中拥有不同的中心性分数，这突出了对齐跨视图中心性以保持多视图一致性的重要性。




实验观察 2

结合下图可知，简单地降低维度以避免中心性问题可能会导致聚类性能不佳，因为在数据压缩过程中可能会丢失关键信息。




(b) Dims vs. SK




(d) Dims vs. ACC

实验观察 3

L2归一化、Z分数归一化和中心L2归一化等已被证明可有效降低中心性的方法，进一步被验证它们成功降低了hubness，同时提高了聚类性能，如图所示。



与此同时，本文证明hubness（偏度）和聚类性能之间存在很强的负相关关系，降低嵌入的hubness可以进一步提高GMVC的性能。




研究方法

本文是第一个强调GMVC方法中Hubness的有害影响，并提出解决方案hubREP (hub-aware Representation Embedding and Pairing)的文章。

1. 简单有效的编码器: **减少Hubness问题**, 同时保留每个视图中的**邻域拓扑**。
2. Hub感知的配对模块: 保持视图之间的**结构一致性**, 从而增强特定视图表示
3. 所提出的hubREP是轻量级, 并**可集成**到现有GMVC方法中的。

研究结论

- 我们首次证明了Hubness问题是多视图聚类中的一个重要潜在问题, 并且对GMVC方法有害。这种分析激发了我们的研究。
- 我们提出了一种简单但有效的特定于视图的编码器, 以消除hubness, 同时保留样本的局部结构, 以便更好地构建图。此外, 所提出的编码器可以灵活地插入以前的GMVC方法中, 这些方法往往侧重于融合方面, 从而提高性能 (见图1) 。
- 我们提出了一种具有 hubaware 配对机制的交叉视图配对方法, 以保持不同视图之间的结构一致性。





实验结果

聚类结果

Method	3Sources						Animal					
	ACC	NMI	ARI	PUR	PRE	F1	ACC	NMI	ARI	PUR	PRE	F1
MCGC (TIP'19[49])	0.4201	0.1491	0.0060	0.4852	0.2350	0.3525	0.1387	0.0636	0.1391	0.1293	0.0703	0.0241
EAMC (CVPR'20[50])	0.3018	0.0899	0.0450	0.4615	0.2948	0.2515	0.2557	0.4031	0.1009	0.3062	0.1975	0.2255
MFLVC (CVPR'22[44])	0.4899	0.3279	0.2103	0.5763	0.3687	0.4115	0.1964	0.1813	0.0712	0.2386	0.1182	0.1259
AECoDDC (CVPR'23[29])	0.3609	0.1712	0.0947	0.5325	0.3494	0.3000	0.2796	0.3841	0.1661	0.3229	0.1864	0.1862
GCFagg (CVPR'23[46])	0.5030	0.4202	0.2704	0.6154	0.4220	0.4638	0.1441	0.1350	0.0615	0.2044	0.1097	0.1176
DFP-GNN TMM'23[43]	0.6450	<u>0.5812</u>	0.5451	0.7396	<u>0.6352</u>	0.6384	0.1856	0.1399	0.0667	0.2226	0.1117	0.1291
DMCAG (IJCAI'23[8])	0.5562	0.4079	0.3289	0.4793	0.5555	0.4822	<u>0.2864</u>	<u>0.4049</u>	<u>0.1689</u>	<u>0.3359</u>	0.1912	0.1878
S ² MVTC (CVPR'24[19])	0.3018	0.0868	0.0124	0.4083	0.2413	0.2542	0.2127	0.1637	0.0689	0.2249	0.1108	0.1357
MVCAN (CVPR'24[45])	0.4260	0.2972	0.1265	0.5030	0.4299	0.4532	0.1303	0.1048	0.0196	0.1854	0.0891	0.1526
SURER (AAAI'24[34])	0.7160	0.5713	0.5551	0.7515	0.6045	0.6837	OOM	OOM	OOM	OOM	OOM	OOM
Ours	0.9290	0.8246	0.8519	0.9408	0.8692	0.8712	0.2966	0.4904	0.2071	0.3590	0.2334	0.2334
Method	BDGP						MNIST-USPS					
	ACC	NMI	ARI	PUR	PRE	F1	ACC	NMI	ARI	PUR	PRE	F1
MCGC (TIP'19[49])	0.4964	0.2743	0.2463	0.4964	0.3767	0.4102	0.4610	0.5271	0.4676	0.4820	0.3182	0.3761
EAMC (CVPR'20[50])	0.5172	0.2977	0.2331	0.5944	0.3977	0.4114	0.5452	0.5120	0.3566	0.5720	0.4476	0.4943
MFLVC (CVPR'22[44])	0.9832	0.9441	0.9586	0.9832	0.9673	0.9672	0.9936	0.9818	0.9858	0.9936	0.9873	0.9873
AECoDDC (CVPR'23[29])	0.4176	0.2164	0.1466	0.5528	0.3213	0.3205	0.9161	0.9367	0.8988	0.9326	0.9172	0.9270
GCFagg (CVPR'23[46])	0.5128	0.3797	0.2541	0.5228	0.4242	0.4267	0.9714	0.9355	0.9380	0.9750	0.9448	0.9448
DFP-GNN TMM'23[43]	0.9676	0.9071	0.9208	0.9708	0.9382	0.9381	0.9161	0.9367	0.8988	0.9326	0.9172	0.9270
DMCAG (IJCAI'23[8])	0.9776	0.9396	0.9453	0.8036	0.9571	0.9571	0.9794	0.9577	0.9556	<u>0.9814</u>	0.9618	0.9617
S ² MVTC (CVPR'24[19])	0.5308	0.3614	0.1999	0.5308	0.3268	0.3912	0.4002	0.3369	0.2142	0.4120	0.2862	0.2950
MVCAN (CVPR'24[45])	0.8284	0.7149	0.8300	0.8300	0.7570	0.7480	<u>0.9822</u>	<u>0.9611</u>	<u>0.9652</u>	0.9568	<u>0.9653</u>	<u>0.9652</u>
SURER (AAAI'24[34])	0.9736	0.9194	0.9352	0.9860	0.9490	0.9491	0.6393	0.5787	0.3714	0.6634	0.5445	0.5653
Ours	0.9868	0.9538	0.9674	0.9916	0.9740	0.9740	0.9572	0.9090	0.9084	0.9592	0.9191	0.9190
Method	Reuters						Noisymnist					
	ACC	NMI	ARI	PUR	PRE	F1	ACC	NMI	ARI	PUR	PRE	F1
MCGC (TIP'19[49])	0.1842	0.0409	0.2058	0.2836	0.1673	0.0031	0.4863	0.5399	0.4063	0.4971	0.3390	0.4930
EAMC (CVPR'20[50])	0.2783	0.0596	0.0474	0.3592	0.2032	0.2267	0.3239	0.2642	0.1451	0.3483	0.2476	0.2483
MFLVC (CVPR'22[44])	0.3625	0.1508	0.1042	0.3817	0.2567	0.2567	0.2497	0.2054	0.0778	0.1905	0.1905	0.2609
AECoDDC (CVPR'23[29])	0.3583	0.1364	0.0942	0.4067	0.2476	0.2489	0.6407	0.5069	0.4356	0.6421	0.4921	0.4908
GCFagg (CVPR'23[46])	0.4667	0.2333	0.1925	0.5083	0.3341	0.3336	0.3249	0.2501	<u>0.1574</u>	0.3653	0.2431	0.2427
DFP-GNN TMM'23[43]	0.5117	0.3089	0.2293	0.5558	0.3716	0.3683	0.4649	0.4416	0.2864	0.5566	0.4051	0.3758
DMCAG (IJCAI'23[8])	<u>0.5908</u>	<u>0.3551</u>	<u>0.3029</u>	<u>0.6083</u>	<u>0.4246</u>	<u>0.4242</u>	0.3215	0.2556	0.1447	0.3585	0.2576	0.2587
S ² MVTC (CVPR'24[19])	0.3325	0.2132	0.1135	0.3833	0.2333	0.3074	0.3091	0.1808	0.1313	0.3173	0.1999	0.2328
MVCAN (CVPR'24[45])	0.3825	0.2553	0.1546	0.4775	0.3211	0.3735	0.5457	0.5118	0.3965	0.6058	0.4671	0.4699
SURER (AAAI'24[34])	0.4575	0.2653	0.1782	0.4925	0.3251	0.3859	0.3432	0.2874	0.1477	0.3805	0.2789	0.2827
Ours	0.6533	0.4330	0.3628	0.6567	0.4921	0.4946	0.6815	0.6802	0.5785	0.6898	0.6205	0.6220
Method	Hdigit						BBCSport					
	ACC	NMI	ARI	PUR	PRE	F1	ACC	NMI	ARI	PUR	PRE	F1
MCGC (TIP'19[49])	0.5723	0.6174	0.5196	0.5725	0.4349	0.5841	0.3511	0.0244	0.0091	0.3713	0.2424	0.3672
EAMC (CVPR'20[50])	0.4803	0.4008	0.2389	0.5066	0.3641	0.4085	0.2904	0.0260	0.0178	0.3989	0.2557	0.2401
MFLVC (CVPR'22[44])	0.9427	0.8709	0.8775	0.9427	0.8926	0.8919	0.6445	0.4502	0.3628	0.6662	0.5134	0.5318
AECoDDC (CVPR'23[29])	0.8827	0.8079	0.7799	0.8834	0.8038	0.8038	0.2978	0.4577	0.0536	0.2327	0.2739	0.0303
GCFagg (CVPR'23[46])	<u>0.9628</u>	0.9231	0.9221	<u>0.9628</u>	0.9300	0.9303	0.5864	0.4010	0.2922	0.5864	0.4496	0.4631
DFP-GNN TMM'23[43]	0.7375	0.6608	0.4964	0.7607	0.6356	0.6159	0.9438	0.8451	0.8541	<u>0.9603</u>	0.8940	0.8943
DMCAG (IJCAI'23[8])	0.9484	<u>0.9480</u>	0.9108	0.9484	0.9387	<u>0.9326</u>	0.6654	0.5629	0.5027	0.7610	0.6109	0.6420
S ² MVTC (CVPR'24[19])	0.8785	0.9524	0.8762	0.8998	0.8277	0.8895	0.8860	<u>0.8860</u>	<u>0.8852</u>	0.9094	0.8486	0.9147
MVCAN (CVPR'24[45])	0.5147	0.5506	0.3795	0.5460	0.4417	0.4520	0.4761	0.3259	0.1308	0.5864	0.4719	0.5057
SURER (AAAI'24[34])	0.9430	0.8849	0.9440	0.8762	0.8945	0.8935	0.9430	0.8440	0.8525	0.9581	0.8925	0.8931
Ours	0.9661	0.9331	<u>0.9295</u>	0.9662	<u>0.9370</u>	0.9377	0.9632	0.8948	0.9070	0.9853	0.9298	0.9297

可视化结果



消融实验

Method	3Sources				BBCSport				BDGP				Reuters			
	ACC	NMI	ARI	PUR	ACC	NMI	ARI	PUR	ACC	NMI	ARI	PUR	ACC	NMI	ARI	PUR
hubREP- $\mathcal{L}_s - \mathcal{L}_c$	0.7065	0.6519	0.5579	0.8201	0.9246	0.8045	0.8104	0.9511	0.7211	0.5991	0.3695	0.7214	0.5102	0.3252	0.2417	0.5418
hubREP- $\mathcal{L}_s$	0.3629	0.1686	0.0755	0.4517	0.4136	0.0654	0.0668	0.4632	0.4778	0.3037	0.1283	0.5403	0.2417	0.1022	0.0336	0.3397
hubREP- $\mathcal{L}_c$	0.8817	0.7619	0.7604	0.8915	0.9400	0.8362	0.8436	0.9559	0.9348	0.8394	0.8469	0.9419	0.5322	0.3987	0.3160	0.5994
hubREP	0.9290	0.8246	0.8519	0.9408	0.9632	0.8948	0.9070	0.9853	0.9868	0.9538	0.9674	0.9916	0.6533	0.4330	0.3628	0.6567

插槽实验

Datasets	Method	SK ↓	HO ↓	ACC ↑	NMI ↑	ARI ↑	#Params ↓
BBCSport	DMCAG [8]	0.9671	0.3058	0.6654	0.5629	0.5027	11.57M
	+ hubREP	0.5846	0.1947	0.8143	0.6654	0.6011	7.94M
BDGP	DMCAG [8]	1.1501	1.380	0.9776	0.9396	0.9453	7.30M
	+ hubREP	0.1783	0.0957	0.9928	0.9821	0.9842	6.00M
Reuters	DMCAG [8]	0.8146	0.2715	0.5908	0.3551	0.3029	23.11M
	+ hubREP	0.7400	0.2682	0.6805	0.6357	0.5011	17.02M
3Sources	DMCAG [8]	1.4033	0.4300	0.5562	0.4079	0.3289	17.94M
	+ hubREP	0.4241	0.0781	<u>0.7456</u>	<u>0.7029</u>	<u>0.5966</u>	12.01M
MNIST-USPS	DMCAG [8]	0.5403	0.1421	0.9794	0.9577	0.9556	7.41M
	+ hubREP	0.1001	0.0736	0.9962	0.9900	0.9916	6.25M



创新不足

- 创新

•

- 局限

•



感悟心得

- 思考

•



笔记摘抄

- Multi-view data, providing diverse information from various domains or sensors of the same target, has gained significant attention in complex tasks, including autonomous driving [39] and disease analysis [26]. In the unsupervised context, multi-view clustering (MVC) [17, 40] aims to leverage the consistent and complementary information inherent in multiview data to group samples into distinct clusters. 多视图数据提供来自同一目标的不同域或传感器的不同信息，在自动驾驶[39]和疾病分析[26]等复杂任务中引起了广泛关注。在无监督环境中，多视图聚类（MVC）[17,40]旨在利用多视图数据固有的一致和互补信息将样本分组为不同的聚类。
 - 后半句修改：多视图聚类旨在无监督模式下，利用多视图数据的一致性和互补信息将样本分组为不同的聚类。
- **In light of the exceptional performance** of deep neural networks, the past few years **have seen a surge** in deep MVC methods. 鉴于深度神经网络的卓越性能, 深度MVC方法在过去几年激增。
- Alternatively,
- **Despite achieving remarkable performance**, the above two groups neglect the intrinsic topological structure of multi-view data, which is inherently fitted to clustering tasks. 尽管取得了显著的性能，但上述两组忽略了多视图数据的内在拓扑结构，而多视图数据本质上适合聚类任务。

- To fully leverage the underlying topology of multi-view data, deep graph-based MVC (GMVC) has become **a dominant branch, with a majority profiting from** the ability of graph neural networks (GNNs) to aggregate neighbor information. 为了充分利用多视图数据的底层拓扑结构, 基于深度图的 MVC (GMVC) 已成为一个主导分支, 其中大多数人受益于图神经网络 (GNN) 聚合邻居信息的能力。
- In particular, current state-of-the-art GMVC approaches, leverage deep autoencoders (AEs) to learn embeddings and then construct similarity-based k-Nearest Neighbor (kNN) graphs from them. This leads to two particular shortcomings. 特别是, 当前最先进的 GMVC 方法利用深度自编码器 (AE) 来学习嵌入, 然后从中构建基于相似性的 k 最近邻 (kNN) 图。这导致了两个特殊的缺点。
 - These methods **are particularly affected by the hubness problem**, where certain points frequently appear in the nearest neighbor lists of other points, resulting in sub-optimal graph construction. 这些方法尤其受到枢纽问题的影响 [23,24], 其中某些点经常出现在其他点的最近邻列表中, 导致图构建不理想。
 - By leveraging deep AEs to obtain the latent representations, they typically do not explicitly encourage the preservation of neighborhood information, leading to sub-optimal embeddings for the clustering-oriented graph generation. 通过利用深度 AE 获得潜在表示, 它们通常不会明确鼓励邻域信息的保存, 从而导致面向聚类的图生成的嵌入次优。
- we first conduct empirical studies demonstrating that GMVC is **indeed vulnerable** to hubness and that hubness reduction techniques can mitigate performance degradation. 我们首先进行实证研究, 证明 GMVC 确实容易受到轮毂的影响, 并且轮毂降低技术可以减轻性能下降。
- Several communities such as cross-model retrieval and zero-shot or few-shot learning **have witnessed** the negative impact of the hubness problem. 跨模型检索和零样本或少样本学习等社区已经见证了枢纽问题的负面影响。
- **As a remedy**, various normalization methods have been utilized to project the representations onto a hypersphere, **which help reduce hubness but do not guarantee a zero data mean**, a prerequisite to eliminate hubness. 作为补救措施, 各种归一化方法被用来将表示投影到超球上, 这有助于减少hub, 但不能保证零数据平均值, 这是消除hub的先决条件。
- **Prevalence of** the hubness problem in MVC.

